

KASTAMONU ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ

BİLGİSAYAR MÜHENDİSLİĞİ ANABİLİM DALI



Çalışma ADI

Toddler Yaş Grubu için ASD Tespiti: Makine Öğrenmesi Modelleri ile Bir Deneysel Çalışma

Ödev raporu

Ad Soyad

Serap HERKİLOĞLU

Danışmanı:

Doç. Dr. Kemal AKYOL

KASTAMONU- 2025
4 HAZİRAN 2025

İÇİNDEKİLER

1. Özet
2. Giriş
 - 2.1. Konunun Tanıtımı
 - 2.2. Amaç ve Kapsam
 - 2.3. Literatür Taraması
3. Yöntem ve Materyal
 - 3.1. Kullanılan Teknolojiler
 - 3.2. Sistem Mimarisi / Algoritma
4. Uygulama ve Sonuçlar
5. Sonuç ve Öneriler
6. Kaynakça
7. Ekler
 - 7.1. Kodlar
 - 7.2. Ekran Görüntüleri

1. Özet

Makine öğrenmesi dersi kapsamında geliştirilecek olan deneysel çalışma için yürütülen bir çalışmanın raporudur. Otizm Spektrum Bozukluğu (OSB) veri seti ile yürütülen çalışma Orjinal ham Veri ile deneysel çalışma (hold-out), Dengesizlik ile başa çıkma deneysel çalışması (hold-out), Normalizasyon deneysel çalışması (hold-out), deneylerinden herhangi birinde k-fold çapraz doğrulama adımlarını içermektedir. Tüm deneysel çalışmalarda en az 3 modelin koşturulmasıyla (Lojistik Regresyon (Logistic Regression), Rastgele Orman (Random Forest), Naive Bayes) 3 model içinden en iyi modelin predict_proba ve predict metotlarına yer verilen veri testinin gerçekleştirilmesini kapsamaktadır. Bu deneysel çalışmalarda karışıklık matrisi, doğruluk, duyarlılık, özgüllük ve F1-skor metrikleri sonuçlarını da bu raporda yer vermiştir. Sonuç olarak Modeller arasından SMOTE ile veri dengesini sağladıktan sonra yapılan makine öğrenmesi modelleri, özellikle Logistic Regression ve Random Forest, yüksek doğruluk ve güvenilirlikle başarılı sonuçlar vermiştir.

2. Giriş

2.1.Konunun Tanıtımı

Yaygın gelişimsel bozukluklar (YGB), sosyal ilişki, iletişim ve bilişsel gelişimde gecikme ya da sapma ile kendini gösteren ve genellikle yaşamın ilk yıllarında başlayan nöropsikiyatrik bozukluklardır. Bu bozukluklar; sosyalleşmede yetersizliği, normal olmayan dil gelişimini, sınırlı davranışları ve ilgileri içeren yaygın görülen klinik belirtilerdir. Amerikan Psikiyatri Birliği, 1994 yılında yaygın gelişimsel bozuklukları beş grupta sınıflandırmış ve otizm spektrum bozukluğunu bu gruplardan biri olarak göstermiştir. Otizm Spektrum Bozukluğu (OSB) DSM-IV (Diagnostic and Statistical Manual of Mental Disorder) ölçütlerine göre tanı alan ve en çok araştırma yapılan bozukluklardan birisidir [1-3]. Bireylerde görülen belirtilerin benzer olmasına rağmen bu belirtilerin bazen bazı bireylerde başlangıç yaşı farklılaşabilir ya da görülme yoğunluğu daha ağır olabilir anlamına gelmektedir [4]. Yıllardır psikolojik bir anormallik olarak kabul edilen otizm spektrum bozukluğuna genellikle yetersiz/soğuk ebeveynliğin neden olduğu inancı üzerinde durularak incelenmiştir. Lakin, Ulusal Ruh Sağlığı Enstitüsü (National Institute of Mental Health) tarafından yapılan girişimlerle “Beynin On Yılı” olarak da isimlendirilen 1990’lı yıllarda yapılan beyin araştırmalarında önemli sonuçlar ortaya çıkmış ve otizm spektrum bozukluğunun, gerçekte beyin fonksiyonlarında olan bir farklılıktan dolayı oluştuğuna yönelik sonuçlar sunulmuştur [5].

Otizm spektrum bozukluğunun genetik, ailesel ve çevresel etmenlerden kaynaklanan bir bozukluk olarak tanımlanmasından günümüze kadar geçen yarım yüzyıllık süre içinde beyin anatomisi, fizyolojisi, histolojisi ve işlevleri alanında yapılan çalışmalar, bu karmaşık sendromun nörobiyolojik bir bozukluk olduğu ve bu bozukluktan dolayı da bireyin sosyal ilişkilerini, iletişim becerilerini, ilgi ve davranışlarını olumsuz etkilediği konusunda önemli veriler sağlamıştır [5-7]. Bununla birlikte tüm bu çalışmalarda, otizm spektrum bozukluğuna yol açan beyin bölgelerinin ve düzeneklerinin kesin olarak saptanabildiğini söylemek olası değildir. Otizm spektrum bozukluğu konusundaki bilgiler, henüz bu bozukluğun önlenmesi ya da temel belirtilerinin uygun tedavisi için yeterli değildir [1]. Otizm spektrum bozukluğu ilk olarak 1943 yılında Amerikalı çocuk psikiyatristi Leo Kanner tarafından, 11 olgu incelenerek ve bu olguların şizofrenden farklı olduğu belirtilerek tanımlanmıştır [8]. Otizm spektrum bozukluğu; bebeklikten itibaren karşısındakinin gözüne bakmada, ortak dikkat ve işaret etme davranışlarındaki yetersizlik ve isteksizlikle kendini belli eden (Aydın, 2008), yaşamın ilk 3 yılında ya da daha öncesinde ortaya çıkan ve ciddi sosyal etkileşim ve iletişim bozukluğunun yanında sosyal davranış, dil, algısal fonksiyonlar, tekrarlayan davranışlar ve ilgilerle kendini gösteren, yaşam boyu süren, yaşla ve olgunlaşma ile belirtilerin görünümünde ve şiddetinde bireyden bireye farklılık gösterebilen, hafiften ağıra kadar değişen çeşitli özellikleri olan gelişimsel nörobiyolojik bir bozukluktur [5, 9-10]. Otizm spektrum bozukluğu çocuğun gelişimini etkilediği için “gelişimsel bozukluk” olarak isimlendirilir[8].

2.2.Amaç ve Kapsam

Bu çalışmada Kaggle’den açık olarak alınmış otizm veri seti [11-14] kullanılarak makine öğrenmesi problemine yönelik farklı veri işleme stratejilerinin ve modelleme yaklaşımlarının sınıflandırma performansına etkisini sistematik bir şekilde analiz etmektir. Bu kapsamda, veri ön işleme adımları, dengesiz veri ile başa çıkma yöntemleri ve farklı doğrulama

stratejileri kullanılarak çeşitli deneysel senaryolar oluşturulmuş ve bu senaryolarda beş farklı makine öğrenmesi modeli test edilmiştir. Bu kapsamda, aşağıdaki deneysel adımlar gerçekleştirilmiştir:

- I. **Orijinal ham veri** kullanılarak, **hold-out** doğrulama yöntemiyle temel bir modelleme süreci yürütülmüştür.
- II. Veri kümesinde bulunan sınıf dengesizliği problemi, uygun yeniden örnekleme yöntemleriyle ele alınmış ve bu müdahalenin model performansına etkisi analiz edilmiştir.
- III. Normalizasyon teknikleri (Min-Max) uygulanarak ölçekleme işleminin sınıflandırma başarımı üzerindeki rolü değerlendirilmiştir.
- IV. İlk beş deneysel çalışmadan biri üzerinde k-fold çapraz doğrulama gerçekleştirilerek modelin genellenebilirliği incelenmiştir.
- V. Her deneysel senaryoda en az beş farklı makine öğrenmesi modeli (örneğin Karar Ağacı, Lojistik Regresyon, SVM vb.) eğitilmiş ve performansları karşılaştırılmıştır.
- VI. En iyi performansı gösteren modelin **predict ve predict_proba** çıktıları üzerinden, **test verisi üzerinde tahminsel analiz** gerçekleştirilmiştir.

Çalışma kapsamında tüm deneysel koşullar altında elde edilen modeller, aşağıdaki performans metrikleri açısından değerlendirmeye alınacaktır. Bunlar:

- a. Karışıklık Matrisi
- b. Doğruluk (Accuracy)
- c. Duyarlılık (Recall / Sensitivity)
- d. Özgüllük (Specificity)
- e. F1-Skoru, Bu kapsam dahilinde, veri işleme teknikleri ile model performansı arasındaki ilişki detaylı olarak incelenerek, elde edilen bulgular yorumlanarak sonuçlandırılmıştır.

2.3.Literatür Taraması

Beş grup psikiyatrik bozukluklardan biri olan Otizm Spektrum Bozukluğu (OSB), bireylerin dilsel, iletişimsel, bilişsel becerilerinin yanı sıra sosyal becerilerini ve yetilerini de sınırlandıran bir zihinsel bozukluktur. Son yıllarda, OSB tanı sürecinin süresini kısaltmak ya da tanı doğruluğunu, duyarlılığını ve özgüllüğünü artırmak amacıyla makine öğrenmesine dayalı akıllı yöntemler, davranış bilimleri alanında yoğun şekilde kullanılmaya başlanmıştır [11]. Makine öğrenmesi, OSB tanı problemini bir sınıflandırma görevi olarak ele almakta ve geçmiş vaka-kontrol örneklerine dayanarak öngörücü modeller geliştirmek için ideal bir yöntem olarak birçok araştırmada yer verilmiştir. Bu modellerin, yukarıda belirtilen hedeflerden bir veya birkaçını gerçekleştirmek üzere tarama araçlarına entegre edilmesi amaçlanarak son beş yılda bazı kaynaklar çalışmanın güvenilirliğini oluşturmaktadır.

Bu çalışmada, OSB sınıflandırmasında makine öğrenmesi kullanan güncel araştırmalar ele alınarak, bu yaklaşımların avantajları ve dezavantajları incelenmiştir. Ayrıca, mevcut OSB tarama araçlarında dikkat çeken önemli bir soruna değinilmiştir: Bu araçların çoğu, DSM-5 yerine DSM-IV tanı kılavuzuna dayanmaktadır. Bu durum, özellikle tarama yöntemlerine gömülü tanı algoritmalarının geçerliliğini tartışmalı hale getirmektedir. Bu nedenle, mevcut tarama araçlarının, DSM-5 ile getirilen yeni OSB sınıflandırma kriterlerini yansıtacak şekilde güncellenmesi zorunlu hale gelmiştir. Sinem KOÇ ve Onur SEVLİ'nin çalışmasında Spektrum Bozukluğu (ASD) teşhisinde farklı sınıflandırıcıların performansını, özellik seçimi yöntemiyle

karşılaştırmaktadır. Spektrum Bozukluğu (ASD) erken teşhisi, erken tedaviye olanak sağladığı için büyük önem taşır. Geleneksel teşhis yöntemlerine ek olarak, makine öğrenmesi teknikleri de teşhis başarısını artırmak amacıyla kullanılmaktadır. 18 özellik değişkeninden (17 giriş, 1 hedef) oluşan bir veri kümesi üzerinde SelectKBest öz nitelik seçimi yöntemi uygulanmış ve dört farklı makine öğrenmesi algoritması (**K-En Yakın Komşu, Lojistik Regresyon, Naive Bayes, Destek Vektör Makineleri**) ile sınıflandırma işlemleri gerçekleştirilmiştir. Performans değerlendirmesi için doğruluk, duyarlılık, özgüllük ve F1 skoru gibi metrikler kullanılmıştır. Özellik seçimi sonrasında Destek Vektör Makineleri ve Lojistik Regresyon algoritmaları **%100 doğruluk** elde ederken, K-En Yakın Komşu ve Naive Bayes sırasıyla **%94.7** ve **%96.7** doğruluk oranlarına ulaşmıştır. Özellik seçimi yapılmadığında ise en yüksek doğruluk oranı **%96.2** olarak kaydedilmiştir [15]. Sedat METLEK, Kıyas KAYAALP'in istik Spektrum Bozukluğunun Makine Öğrenme Algoritmaları ile Tespiti adlı çalışmasında, Otizm Spektrum Bozukluğu (ASD) tanısında makine öğrenmesi algoritmalarının etkinliğini incelemektedir. ASD, 12-36 ay arasındaki çocuklarda atanısına yardımcı olabilecek bir karar destek yazılımı geliştirilmiştir. Yazılım geliştirme sürecinde gözetimli ve gözetimsiz olmak üzere altı farklı makine öğrenmesi algoritması test edilmiştir. Sonuçlar, gözetimli öğrenme algoritmalarının gözetimsiz öğrenme algoritmalarına göre daha başarılı olduğunu ortaya koymuştur. Özellikle Destek Vektör Makineleri (SVM) ile yapılan sınıflandırmada **%100 başarı** oranı elde edilmiştir [16]. Çocuklarda Otizm Spektrum Bozukluğu Tahmini için Makine Öğrenmesi Kullanımının da ise Mahmoud ve ekibi günümüzde ASD tanısı için standart klinik testler temel yöntem olarak kabul etmiş olsalar da bu testler zaman alıcı ve maliyetlinden yola çıkarak **Destek Vektör Makineleri (SVM), Rastgele Orman (RF), Naive Bayes, Lojistik Regresyon (LR), K-En Yakın Komşu (KNN) ve Karar Ağaçları (DT)** gibi **makine öğrenmesi sınıflandırma modellerinin** ASD teşhisindeki uygulanabilirliği araştırılmıştır. Modelleme için Kaggle ve UCI ML gibi açık erişimli platformlardan elde edilen dört farklı ASD veri kümesi (bebekler, çocuklar, ergenler ve yetişkinler) kullanılmıştır. Ana hedef, çocukluk döneminde ASD riskini belirleyerek teşhis sürecini hızlandırmaktır. Bulgularımıza göre, seçilen veri kümesinde **Lojistik Regresyon (LR)** en yüksek doğruluk oranını sağlamıştır [17]. Mengyi Liao ise Mevcut ASD tespit yöntemleri uzman değerlendirmelerine dayanarak öznel ve maliyetli olabilmesine alternatif yöntem olarak, erken teşhis sürecini hızlandırarak maliyetleri düşürmeyi hedefleyerek çalışmada, yenilikçi bir özellik çıkarım yöntemi kullanılarak **göz fiksasyonu, yüz ifadesi ve EEG verileri** analiz edilmiştir. Ardından, ağırlıklı Naive Bayes algoritmasına dayalı hibrit bir füzyon yöntemi uygulanarak **%87.50 doğruluk** oranına ulaşılmıştır. Sonuçlar, makine öğrenmesi tabanlı sınıflandırma yaklaşımının ASD'nin erken tespiti için etkili olduğunu göstermektedir. EEG verilerinin en ayırt edici bilgi kaynağı olduğu ve fizyolojik ve davranışsal verilerin birbirini tamamlayıcı özellikler taşıdığı belirlenmiştir. Bu nedenle, çalışmada önerilen çok modlu veri füzyonuna dayalı makine öğrenmesi yaklaşımı, ASD teşhisinde doğruluğu önemli ölçüde artırmaktadır [18]. Diğer bir çalışma olan Hindistan Otizm Değerlendirme Ölçeği (ISAA)'ni kullanarak makine öğrenmesi tabanlı otizm sınıflandırma modeli geliştirmeyi amaçlamaktadır. Eklenen **6 özellik** ile, SVM modelinin geleneksel ISAA parametrelerine göre **%85.7 F1 skoru** ve **%90 doğruluk** ile daha iyi performans gösterdiği bulunmuştur. MLP modeli de benzer sonuçlar sağlamış ve model, tarafsız, doğru ve zaman açısından verimli bir tarama yöntemi olarak öne çıkmıştır [19]. Otizm Tarama: Denetimsiz Makine Öğrenmesi Yaklaşımı çalışması Otizm tanısı ve tarama verileriyle ilgili bir sorun tespitiyle, tahminlerin çoğunlukla tıbbi tarama yöntemleri tarafından sağlanan puanlara dayanmasından; bu puanlar, nasıl hesaplandığına bağlı olarak yanlış olabileceğinden yola çıkarak oluşabilecek

yanlılığı azaltmayı amaçlayarak, **Self-Organizing Map (SOM)** ve **sınıflandırma algoritmalarından** oluşan yeni bir model ile tarama sürecine ilişkin tahminlerin performansını değerlendirmiştir. SOM, tanı sürecinden önce, bağımsız özelliklerden öğrenilen kümelerle yeni bir sınıf etiketi üretmek için kullanılır. Kümeler, giriş veri setindeki iletişim, tekrarlayan özellikler ve sosyal özelliklerle ilişkilidir. Ardından, yeni kümeler mevcut sınıf etiketleriyle karşılaştırılarak tutarsızlıklar giderilir ve düzeltilir. Son olarak, düzeltilmiş veri seti, otizm tanısı için sınıflandırma sistemlerini üretmek için kullanılır. Yeni model, **2000'den** fazla örnek içeren gerçek hayat otizm tarama veri seti üzerinde değerlendirilmiştir. Düzeltilmiş veri setine dayalı sonuçlar, önerilen yöntemin orijinal veri setinden türetilen modellerle karşılaştırıldığında, sınıflandırma modelleri için anlamlı şekilde daha yüksek doğruluk, hassasiyet ve duyarlılık sağladığını göstermektedir [20]. “Makine Öğrenimi Yaklaşımları ile Erken Otizm Spektrum Bozukluğu Tespiti Üzerine Bir İnceleme” adlı Nawshin ve ekibinin çalışması çocuklar ve bebeklerde otizm tahmin etmek için **Lojistik Regresyon, Destek Vektör Sınıflandırıcı (SVC), K-En Yakın Komşu (KNN), Karar Ağaçları ve Rastgele Orman** gibi makine öğrenimi tekniklerinin uygulamasını incelemektedir. Bu tekniklerin etkinliği, her iki yaş grubuna özgü kamuya açık veri setleri kullanılarak değerlendirilmiştir. Bulgular, özellikle bebek veri seti için **Destek Vektör Sınıflandırıcı ile %100 kesişim oranı ve Lojistik Regresyon ile %99,80 kesişim oranı başarılarıyla** dikkat çekicidir. Benzer şekilde, çocuk veri seti, Destek Vektör Sınıflandırıcı ile **%100 kesişim oranı** ve Lojistik Regresyon ile **%99,96 kesişim oranı** başarıları göstermektedir. Ayrıca, gerçek dünyadan alınan çocuk (4-11 yaş) veri setinde tüm algoritmalar **%100 doğruluk** elde etmiştir. Lojistik Regresyon, Rastgele Orman, Destek Vektör Sınıflandırıcı ve Karar Ağaçları, gerçek dünya veri setiyle **%100 doğruluk ve kesişim oranı** elde etmiştir. Bu sonuçlar, makine öğreniminin çocuklar ve bebeklerde otizmin erken tespiti için büyük bir potansiyele sahip olduğunu ve gelecekteki araştırmalar ve klinik uygulamalar için umut verici yollar sunduğunu vurgulamaktadır [21]. Makine öğrenimi (ML) uygulamaları, ASD tahmin ve tanısını devrim niteliğinde dönüştürme potansiyeline sahip bir yol sunduğu düşünülerek bu çalışma **Amr ve arkadaşları tarafından yürütülmüştür**. Bu çalışmanın amacı, ML ve Otomatik Makine Öğrenimi (AutoML) tekniklerini, kapsamlı veri setleri ve ileri düzey analizlerle birleştirerek ASD tespit ve tahmin yeteneklerini geliştirmektir. Çalışma, metin tabanlı veri setlerinde ML ve AutoML'yi sistematik bir şekilde uygulayan Otizm Spektrum Bozukluğu Tespiti (ASD) Çerçevesini tanıtmaktadır. Farklı veri kaynaklarının birleştirilmesiyle oluşturulan birleşik bir veri seti, tanısallık kapsamı zenginleştirmektedir. Bu çerçeve, **Lazy Predict, TPOT ve AutoKeras gibi AutoML araçlarını, Principal Component Analysis (PCA) ve Ki-Kare gibi öznelik seçme yöntemlerini, Bayesian optimizasyonu, Random Search ve genetik algoritmalar** gibi güçlü hiperparametre optimizasyon tekniklerini, ayrıca tahmin doğruluğunu artırmak için oylama ve **bagging** gibi gelişmiş topluluk yöntemlerini kullanmaktadır. **Yedi veri seti**, bunlardan biri de **DB8** adlı sentezlenmiş veri seti olmak üzere **27 farklı ML modelinin** ampirik değerlendirilmesi, pek çok modelin farklı bağlamlarda **%100 doğruluk** ve mükemmel F1 skorları elde ettiğini göstermektedir. Bu sonuçlar, önerilen çerçevenin ASD tespit ve tahmin metodolojilerini geliştirmede ne kadar etkili olduğunu vurgulamıştır[22]. **Khosro Rezaee** bireysel yürüttüğü derlemeyse, ASD'nin otomatik teşhisinde kullanılan makine öğrenimi yöntemlerini kapsamlı bir şekilde incelemektedir. Makine öğrenme algoritmalarının, ASD'nin tanısında geleneksel yöntemlere kıyasla daha hızlı ve doğru sonuçlar sunduğu görülmüştür. Çalışmada, çeşitli makine öğrenimi algoritmaları, veri ön işleme teknikleri ve özellik seçimi yöntemleriyle ASD'nin tanısındaki başarıları ele alınmıştır. Ayrıca, makine öğrenimi tabanlı otomatik teşhis sistemlerinin ASD

tespiti için yüksek doğruluk, hassasiyet ve güvenilirlik sağladığı vurgulanmaktadır. Çalışma, makine öğrenmesinin ASD tanısında kullanılan veri setlerinin çeşitliliği, algoritma çeşitliliği ve gelecekteki araştırmalar için potansiyel geliştirme alanlarına da değinmektedir. Sonuç olarak, makine öğrenimi uygulamalarının ASD tanısının otomatikleştirilmesi sürecinde önemli bir ilerleme kaydettiği ve bu alanda daha fazla araştırma yapılması gerektiği belirtilmiştir. Bu incelemeler literatürde Otizm Spektrum Bozukluğu Tespiti (ASD) için makine öğrenmesiyle geliştirilen ve geliştirilmek üzere olan yenilikçi yaklaşımların önemini ve kullanılabilirliğini bizlere kanıtlamıştır [23]. Zhong Zhao ve ekibi çalışmada, yüz yüze konuşmalar sırasında elde edilen göz takip verilerini kullanarak çocuklarda OSB'yi sınıflandırmayı amaçlamıştır. SVM algoritması, **%92.31** doğruluk oranıyla en yüksek performansı gösteren çalışmalardandır [24]. Bununla birlikte Chris Jungwoo Pae, Nichole Hyunwoo Pae ise F. Thabtah [12-14] tarafından sağlanan veri seti üzerinde çeşitli denetimli makine öğrenmesi algoritmalarını değerlendirerek OSB taramasında SVM'in etkinliğini incelemiştir [25]. Nabil ve çalışma arkadaşları evde çekilen videolar üzerinden davranışsal özellikleri değerlendirerek OSB tanısı koymayı hedeflemiştir. SVM modeli kullanarak, **%94.05** doğru pozitif oranlı bir model ortaya atmışlardır. Bu bizlere SVM modelinin görüntü ve daha karmaşık verilerde başarılı sonuçlar verdiğini göstermiştir [26]. K-En Yakın Komşu (KNN) algoritması, Otizm Spektrum Bozukluğu (OSB) tanısında etkili bir makine öğrenmesi yöntemi olarak çeşitli çalışmalarda değerlendirilmiştir. Sakshi Gupta, Dr. dayashankar Pandey KNN algoritmasını kullanarak OSB'yi tahmin etmeyi amaçlamıştır. KNN, yüksek doğruluk, hassasiyet, geri çağırma ve F1 skoru ile etkili bir yöntem olarak değerlendirilmiştir [27]. Bu çalışma KNN için referans olarak değerlendirilebilir. çocuklarda OSB'yi tahmin etmek için KNN algoritmasını kullanmıştır. Najat S. Bousidrah ve ekibi ise çocukların veri seti ile KNN modelinin, **%87.14** doğruluk oranı ile diğer modellerden daha iyi performans göstermiştir [28]. Sabreen Waheed Kadhum, Mohammed Ali Tawfeeq tarafından yapılan başka bir çalışmada, 1250 vakalık bir ASD veri seti kullanılarak en yüksek Pearson korelasyon katsayısına sahip beş belirleyici özellik (cinsiyet, konuşma gecikmesi, sarılık, genetik bozukluklar ve aile geçmişi) seçilmiş ve Naive Bayes, KNN, Karar Ağacı, SVM ve AdaBoostM1 algoritmalarıyla performans analizleri gerçekleştirilmiştir. Elde edilen sonuçlar, özellikle Naive Bayes **%99.2** doğruluk ve KNN **%97.2** doğruluk modellerinin yüksek başarı ve düşük tahmin süresiyle dikkat çektiğini, buna karşın SVM'nin **%80.4** doğruluk en düşük performansı sergilediğini ortaya koymuştur [29]. Yapılan çalışmalara bakıldığında bulgular, ASD teşhisinde özellikle basit ve hızlı çalışan algoritmaların önemli bir potansiyele sahip olduğunu göstermektedir.

3. Yöntem ve Materyal

3.1. Kullanılan Teknolojiler

Bu çalışmada, otizm spektrum bozukluğu (ASD) tanısının erken yaşta yapılabilmesine yönelik olarak makine öğrenmesi yöntemleriyle bir dizi deneysel analiz gerçekleştirilmiştir. Çalışmada kullanılan veri seti, Kaggle platformunda yer alan "**Autism Screening for Toddlers**" veri setidir. Veri, **Q-CHAT-10** testine dayalı olarak toplanmış ve sınıflandırma problemleri için uygun hale getirilmiştir. Çalışma Python programlama dili **kullanılarak Google Colab** ortamında gerçekleştirilmiştir. Veri seti **%70** eğitim ve **%30** test olarak ayrılmıştır. Ham veriyle doğrudan modeller eğitilmiş ve başarı metrikleri değerlendirilmiştir. Veride gözlemlenen sınıf dengesizliği, **SMOTE (Synthetic Minority Oversampling**

Technique) yöntemi ile giderilerek pozitif sınıf örnekleri sentetik olarak artırılmıştır, böylelikle modelin duyarlılığı iyileştirilmiştir. Özniteliklerin dağılımını daha homojen hale getirmek amacıyla **StandardScaler** kullanılarak veri normalleştirilmiştir. Bu özellikle **Naive Bayes ve Lojistik Regresyon** gibi modellerin başarısını artırmıştır. Model başarısının daha güvenilir ölçülebilmesi için **5 katlı K-Fold (StratifiedKFold)** çapraz doğrulama uygulanmıştır. Bu yöntemle her model farklı veri bölmelerinde test edilerek ortalama performans metrikleri elde edilmiştir. Çalışma kapsamında beş farklı makine öğrenmesi modeli kullanılarak karşılaştırmalı bir analiz gerçekleştirilmiştir. İncelenen modeller şunlardır:

I. Lojistik Regresyon (Logistic Regression)

II. Rastgele Orman (Random Forest)

III. Naive Bayes

IV. Destek Vektör Makineleri (Support Vector Machines - SVM)

V. K-En Yakın Komşu (K-Nearest Neighbors - KNN)

Her deneysel çalışmada aşağıdaki sınıflandırma metrikleri kullanılarak modellerin performansı ölçülmüştür:

- Accuracy (Doğruluk)
- Precision (Kesinlik)
- Recall (Duyarlılık / Sensitivity)
- Specificity (Özgüllük)
- F1 Score
- Confusion Matrix (Karışıklık Matrisi)
- Yapılan değerlendirmeler sonucunda en başarılı model seçilerek, bu modelin **predict()** ve **predict_proba()** metodlarıyla test verisi üzerindeki performansı ayrıca raporlanmıştır.

3.2.Sistem Mimarisi / Algoritma

Kullanılan veri seti, ASDTests uygulaması üzerinden toplanmış ve etik onaylıdır. Veri setinde eksik değer kontrolü yapılmış ve bulunmamaktadır. Kategorik değişkenler etiket kodlama (label encoding) ve one-hot encoding gibi yöntemlerle sayısal hale getirilmiştir. Sınıf dengesizliği gözlemlendiği için **SMOTE (Synthetic Minority Over-sampling Technique)** kullanılarak dengeleme sağlanmıştır. Normalizasyon adımında, Naive Bayes modeline uygunluk açısından **MinMaxScaler** kullanılmıştır. Veri seti, **Hold-Out yöntemi** ile %70 eğitim, %30 test olacak şekilde ayrılmıştır. Ek olarak, belirli deneylerde **k-fold çapraz doğrulama (k=5)** yöntemi ile model genel performansı değerlendirilmiştir. Beş farklı sınıflandırma algoritması kullanılmıştır:

I. Lojistik Regresyon (Logistic Regression)

II. Rastgele Orman (Random Forest)

III. Naive Bayes


IV. Destek Vektör Makineleri (Support Vector Machines - SVM)

V. K-En Yakın Komşu (K-Nearest Neighbors - KNN)

Her bir adım, orijinal veri, dengelenmiş veri ve normalize edilmiş veri üzerinde eğitilmiş ve test edilmiştir. Modellerin başarısı aşağıdaki performans metrikleri ile değerlendirilmiştir. En başarılı performansı gösteren modelin **predict()** ve **predict_proba()** metodları test verisi üzerinde uygulanarak, sınıflandırma ve olasılık temelli tahmin sonuçları sunulmuştur. Bütün modellerin sonuçları tablo halinde karşılaştırılmış ve en iyi model seçilmiştir.

4. Uygulama ve Sonular

Ham veriler ile alıřma yrtldğnde sonular ařağdaki grsellerde belirtildiğ şekilde olmaktadır.



Garfik-1: karışıklık matrisleri

Logistic Regression ve Random Forest modelleri test verisini **%100 doğrulukla** sınıflandırmış. Naive Bayes modelinde ise **3 hata mevcut: 1 yanlış pozitif ve 2 yanlış negatif** veride hata yapmıştır. Her matrisin içinde hücrelerdeki sayılar, modelin tahminlerinin ne kadar doğru olduğunu açık şekilde göstermektedir.

Model Performans Karşılaştırması (F1 Score'a göre sıralı)

Model	Accuracy	Precision	Recall (Sensitivity)	Specificity	F1 Score
Logistic Regression	1.0	1.0	1.0	1.0	1.0
Random Forest	1.0	1.0	1.0	1.0	1.0
Naive Bayes	0.9905362776025236	0.9954128440366973	0.9908675799086758	0.9897959183673469	0.9931350114416476
Support Vector Machine	0.9905362776025236	1.0	0.9863013698630136	1.0	0.993103448275862
K-Nearest Neighbors	0.9684542586750788	0.986046511627907	0.9680365296803652	0.9693877551020408	0.9769585253456221

Tablo-1: Performans Ölümlerinin F1 score'a göre sıralanması

Tablo-1'de, beř farklı makine ğrenmesi modelinin karşılařtırmalı performans lümlerini grsel olarak sunmaktadır. Her bir model iin doğruluk, kesinlik, duyarlılık, zgllk ve F1 skoru gibi nemli sınıflandırma metrikleri yer almaktadır. zellikle **Logistic Regression ve Random Forest** modelleri tm metriklerde maksimum bařarı gstermiřtir.

En iyi model: Logistic Regression

Predict Proba & Tahmin Edilen Sınıf (İlk 5 rnek)

Class 0 Prob	Class 1 Prob	Predicted Class
0.0	1.0	1.0
0.0	1.0	1.0
0.999793	0.000207	0.0
0.05053	0.94947	1.0
0.904153	0.095847	0.0

Tablo-2: Predict_proba Sonucu ve Predict Tahmini

1 (ASD Traits olan grup): 728 rnek, oran olarak yaklařık **% 69.1**
0 (ASD Traits olmayan grup): 326 rnek, oran olarak yaklařık **% 30.9**


ASD özelliklerine sahip olan sınıf (1) veri setinin yaklaşık %69'unu oluşturuyor, yani çoğunlukta. Diğer sınıf (0) ise yaklaşık %31, yani daha az örnek içeriyor. Bu oranın dengeli olmaması, makine öğrenmesi modellerinde sınıflar arası dengesizliği oluşturması ihtimali nedeni ile düzenlenmiştir. Dengesiz veri setlerinde, özellikle azınlık sınıfın tahmini zorlaşabileceğinde model çoğunluk sınıfa odaklanabilmektedir. Bu durumda, örneğin 0 sınıfını iyi tanımayan ama 1 sınıfını iyi tanıyan modeller ortaya çıkabileceğinden, örneklem artırma (**oversampling**), azaltma (**undersampling**) ya da ağırlıklandırma gibi yöntemlerle sınıf dağılımı dengelenebilmektedir. Veri seti büyüklüğü açısından uygun olarak kabul edilmektedir. Toplam **1054 örnek var (728 + 326)**, bu büyüklük küçük veya orta ölçekli bir veri seti olarak değerlendirilebilir. Veri miktarının artırılması modelin genelleme yeteneğini artıracaktır. Sınıf dağılımı oransal olarak belirgin bir dengesizlik gösterdiği için analiz veya modelleme sürecinde buna dikkat etmek, sınıf dengesini sağlamak için uygun yöntemleri kullanmaya önem verilmiştir. SMOTE ile artırma (oversampling) sonrası sınıf dağılımı dengelenmiş, her iki sınıf da eşit sayıda (**582 örnek**) oluşturulmuştur.

```
Oversampling sonrası sınıf dağılımı:
Class/ASD Traits
1      582
0      582
Name: count, dtype: int64
```

SMOTE Sonrası Modellerin Performansı

Model	Accuracy	Precision	Recall (Sensitivity)	Specificity	F1 Score	ROC AUC
Logistic Regression	1.0	1.0	1.0	1.0	1.0	1.0
Random Forest	1.0	1.0	1.0	1.0	1.0	1.0
Support Vector Machine	1.0	1.0	1.0	1.0	1.0	1.0
K-Nearest Neighbors	0.9716	1.0	0.9589	1.0	0.979	0.9956
Naive Bayes	0.9526	0.9359	1.0	0.8462	0.9669	0.9974

Tablo-3: SMOTE Sonrası Modelin Performansı



Grafik-2: SMOTE Sonrası F1 Skorları

Tablo-3' den yola çıkarak SMOTE sonrası modeller çok iyi sonuç verdiği görülmektedir, sınıf dengesizliği de başarıyla giderilmiştir.

Normalizasyon Sonrası Seçilen 5 Modelin Performansı

Model	Accuracy	Precision	Recall (Sensitivity)	Specificity	F1 Score
Logistic Regression	1.0	1.0	1.0	1.0	1.0
Random Forest	1.0	1.0	1.0	1.0	1.0
SVM	0.991	0.993	0.993	0.985	0.993
Naive Bayes	0.981	0.98	0.993	0.954	0.986
KNN	0.967	0.993	0.959	0.985	0.976

Tablo-4: Normalizasyon Sonrası Modellerin Performansı

Tablo-4. Ve Tablo-3 kıyaslandığında Normalizasyon veri ön işleme aşamasında çok önemli ve özellikle bazı modeller için kritik olduğu görülmektedir. Logistic Regression ve Random Forest gibi modeller ölçeklerden daha az etkilenirken, Naive Bayes gibi istatistiksel modeller bundan daha çok verim aldığı görülmektedir.

K-Fold Çapraz Doğrulama Sonuçları

Model	Accuracy	Precision	Recall (Sensitivity)	F1 Score
Logistic Regression	1.0	1.0	1.0	1.0
Random Forest	1.0	1.0	1.0	1.0
Naive Bayes	0.9734281200631912	0.9809911505155731	0.9807463391591874	0.9808049947882436
SVM	0.9886120514556535	0.9877824287804717	0.9958809636277751	0.9917993634397693
KNN	0.9601489505754909	0.9817479820648835	0.9601700519603211	0.9708226784895659

Tablo-5: K-Fold Çapraz Doğrulama Sonuçları

Modeller K-Fold ile de %100 başarı sağlamışlardır. Bu, modelin aşırı uyum (overfitting) yapmadığını ve farklı alt veri kümelerinde de tutarlı performans gösterdiğini düşündürmektedir. Bu da sonuçlar gerçekliğinin, veri seti küçüklüğü ya da çok belirgin özelliklerden kaynaklanabileceğini düşündürmektedir. Tablo-5’de Naive Bayes için K-Fold ile performans biraz düştüğünü ama hâlâ ham veriye göre çok yüksek olduğu görülmektedir. **Accuracy %97.3, Precision ve Recall ~98** civarında olmasıyla sonuç modelin genelleme yeteneğinin güçlü olduğunu gösterdiği için aşırı uyum (overfitting) durumu olma ihtimalinin düşük olduğu kanısına varılmıştır.

5. Sonuç ve Öneriler

En iyi modelin performans tablosu:


	Model	Accuracy	Precision	Recall (Sensitivity)	Specificity	F1 Score	ROC AUC
0	Logistic Regression (SMOTE + Normalizasyon)	0.952607	0.935897	1.0	0.846154	0.966887	0.997366

Bu çalışma kapsamında değerlendirilen beş farklı makine öğrenmesi modelinin performansları; doğruluk (accuracy), kesinlik (precision), duyarlılık (recall), özgüllük (specificity), F1 skoru ve ROC AUC gibi çeşitli sınıflandırma başarı ölçütleri kullanılarak karşılaştırılmıştır. Uygulanan SMOTE yöntemi ve verilerin standartlaştırılması sonrasında elde edilen sonuçlara göre, ****Logistic Regression**** modeli en iyi performansı göstermiştir.

Bu model, doğruluk: 1.000, kesinlik: 1.000, duyarlılık: 1.000, özgüllük: 1.000, F1 skoru: 1.000 ve ROC AUC: 1.000 değerleriyle hem pozitif sınıfı doğru tanılamadaki başarısı (duyarlılık), hem de yanlış pozitif oranının düşüklüğü (özgüllük) açısından öne çıkmıştır.

Bu nedenle, analizlerde ve uygulamalarda bu çalışmadan yola çıkarak Logistic Regression modelin tercih edilmesi uygun görülmüştür.

Görsel-1: En İyi Modelin Performansı Açıklaması



Grafik-3: K: En İyi ve En Kötü İki Modelin Performansı Grafiği

Otizm spektrum bozukluğu (ASD), bireylerin sosyal iletişim ve davranışlarında çeşitli zorluklar yaşadığı nörogelişimsel bir durumdur. Otizmin erken tanısı, uygun müdahale ve desteklerin zamanında başlaması açısından kritik öneme sahiptir[15-21]. Geleneksel tanı yöntemleri genellikle uzman değerlendirmelerine dayanırken, makine öğrenmesi teknikleri bu süreci daha objektif, hızlı ve doğru hale getirme potansiyeli taşıdığı artık kabullenilmiş bir gerçektir. Makine öğrenmesi, bilgisayarların veriden öğrenerek belirli görevleri yerine getirmesini sağlar; özellikle karmaşık ve çok boyutlu verilerde gizli kalmış örüntüleri ortaya çıkarabilir [30]. Otizm tanısı için geliştirilen modeller, davranışsal, genetik veya biyomedikal verileri kullanarak otizme özgü özelliklerin tespiti ve sınıflandırılması amacıyla uygulanmaktadır. Ancak, otizm gibi karmaşık ve heterojen bir bozuklukta başarılı model geliştirmek için veri kalitesi, sınıf dengesizliği ve model genelleştirme gibi zorluklar dikkatlice ele alınmalıdır. Bu noktada, veri dengesizliğini gidermek için SMOTE gibi yöntemlerle sınıflar eşitlenmesi yürütülmüştür, veri ön işleme ve normalizasyon teknikleri uygulanmıştır. Elde edilen modellerin performansı, doğruluk, hassasiyet (precision), duyarlılık (recall), özgüllük (specificity) ve F1 skoru gibi metriklerle değerlendirilerek en iyi modelin ne olacağına cevap verilmiştir. Böylece, makine öğrenmesi otizm tanısında destekleyici, hassas ve tekrarlanabilir çözümü hangi modelle sunacağını gösterilmiştir; ancak klinik uygulamalar için model doğrulama ve genelleme yeteneğinin titizlikle test edilmesi ve veri setinin daha da artırılması gerekmektedir. Literatürde denen yöntemlerin hibrit modellerle daha farklı kombinasyonlarla denenmesi de bu alandan yenilikçi bir yaklaşım sunacağı düşünülmektedir. Lakin bu çalışmada en iyi sonuç Görsel-1 de belirtilen Logistic Regression (SMOTE + Normalizasyon) olarak belirlenmiştir. Ama bu diğer modellerin başarısız olduğunu düşündürmemelidir. Görsel-2’de diğer modellerinde iyi sonuçlar verdiği gösterilmektedir. Sadece bu çalışma literatürdeki çalışmalar gibi bir çok veri setinin birleştirilmesi ile büyütülerek gerçek dünya uygulaması olarak geliştirilebileceğini bizlere göstermiştir.

6. Kaynakça

- [1] Ulay, H. T., & Çengel-Kültür, S. E. (2010). Otizm. *Clinic Pediatri*, 5, 33-43.
- [2] Magyar, C. I. (2011). *Developing and evaluating educational programs for students with autism*. NY, London: Springer Science+Business Media, LLC.
- [3] American Psychiatric Association (1980). *Diagnostic and statistical manual of mental disorders*. Third Edition, Washington DC: APA.
- [4] Kanner, L. (1943). "Autistic Disturbances of Affective Contact", *Nervous Child* 2, 217-250. Reprinted in *Childhood Psychosis: Initial Studies and New Insights*, ed. Leo Kanner (Washington, D.C.: V. H. Winston, 1973). Also reprinted in *Classic Readings in Autism*, ed. Anne M. Donnellan (New York: Teacher's College Press, 1985). <http://www.tohumotizmportali.org/Content/Pdf/Autistic-Disturbances-of-Affective-Contact.pdf> adresinden 28 Temmuz 2014 tarihinde edinilmiştir.
- [5] Geller, L. (2008). *The changing face of autism*. V. Starsia ve R. Day Gore (Eds.), Edited by The Healing Project. *Voices of Autism. The Healing Companion: Stories for Courage, Comfort and Strength. "Voices Of" Series Book No. 5* (ss.19- 27). New York: LaChance Publishing LLC.
- [6] Ministry of Children and Family Development [MCFD]. (2013). *A parents' handbook: Your guides to autism program*. British Columbia.
- [7] Szatmari, P., & Jones, M. B. (2007). *Genetic epidemiology of autism spectrum disorders*. F. R. Volkmar (Ed.) *Autism and Pervasive Developmental Disorders*. Second Edition (ss. 157-178). Cambridge, New York: Cambridge University Press.
- [8] ÖZKAN, Ş. Y., ERGENEKON, Y., ÇOLAK, A., KAYA, Ö., & CAVKAYTAR, S. (2015). Otizm spektrum bozukluğu. A. Cavkaytar (Ed.). *Aile ve Sosyal Politikalar Bakanlığı*.
- [9] Aydın, A., & Saraç, T. (2014). Otistik bireylerin özellikleri ile ebeveynlerinin geniş otizm fenotipi ve aleksitimik özelliklerinin incelenmesi. *The Journal of Academic Social Science Studies (JASSS)*. *International Journal of Social Science*, 24, 183-209.
- [10] Fein, D., & Dunn, M. (2007). *Autism in your classroom: A general educator's guide to students with autism spectrum disorders*. Bethesda: Woodbine House, Inc.
- [11] Thabtah, F. (2017). *Autism Spectrum Disorder Screening: Machine Learning Adaptation and DSM-5 Fulfillment*. *Proceedings of the 1st International Conference on Medical and Health Informatics 2017*, pp.1-6. Taichung City, Taiwan, ACM.
- [12] Thabtah, F. (2017). *ASDTests. A mobile app for ASD screening*. www.asdtests.com [accessed December 20th, 2017].
- [13] Thabtah, F. (2017). *Machine Learning in Autistic Spectrum Disorder Behavioural Research: A Review*. *Informatics for Health and Social Care Journal*.
- [14] Thabtah F, Kamalov F., Rajab K (2018) *A new computational intelligence approach to detect autistic features for autism screening*. *International Journal of Medical Informatics*, Volume 117, pp. 112-124.
- [15] Koç, S., & Seveli, O. (2025). Otizm Spektrum Bozukluğu Tanısında Öznitelik Seçimi Yoluyla Farklı Sınıflandırıcıların Karşılaştırılması. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 37(1), 61-74. <https://doi.org/10.35234/fumbd.1501652>
- [16] Metlek, S., & Kayaalp, K. (2020). Otistik Spektrum bozukluğunun makine öğrenme algoritmaları ile tespiti. *Journal of Intelligent Systems: Theory and Applications*, 3(2), 60-68.
- [17] Abdelwahab, M. M., Al-Karawi, K. A., Hasanin, E. M., & Semary, H. E. (2024). *Autism spectrum disorder prediction in children using machine learning*. *Journal of Disability Research*, 3(1), 20230064.

- [18] Chen J., Wang G., Zhang K., Wang G., and Liu L., A pilot study on evaluating children with autism spectrum disorder using computer games, *Computers in Human Behavior*. (2019) **90**, 204–214, <https://doi.org/10.1016/j.chb.2018.08.057>, 2-s2.0-85054670993.
- [19] Lord C, Risi S, DiLavore PS, Shulman C, Thurm A, Pickles A (2006) Autism from 2 To 9 years of age. *Arch Gen Psychiatry* PubMed 63(6):694–701. <https://doi.org/10.1001/archpsyc.63.6.694>
- [20] Alahmari, F. (2020). A comparison of resampling techniques for medical data using machine learning. *Journal of Information & Knowledge Management*, 19(01), 2040016.
- [21] Haque, N., Islam, T., & Erfan, M. (2025). An exploration of machine learning approaches for early Autism Spectrum Disorder detection. *Healthcare Analytics*, 100379.
- [22] Rashed, A. E. E., Bahgat, W. M., Ahmed, A., Farrag, T. A., & Atwa, A. E. M. (2025). Efficient machine learning models across multiple datasets for autism spectrum disorder diagnoses. *Biomedical Signal Processing and Control*, 100, 106949.
- [23] Rezaee, K. (2025). Machine learning in automated diagnosis of autism spectrum disorder: a comprehensive review. *Computer Science Review*, 56, 100730.
- [24] Zhao, Z., Tang, H., Zhang, X., Qu, X., Hu, X., & Lu, J. (2021). Classification of Children With Autism and Typical Development Using Eye-Tracking Data From Face-to-Face Conversations: Machine Learning Model Development and Performance Evaluation. *Journal of medical Internet research*, 23(8), e29328. <https://doi.org/10.2196/29328>
- [25] Jungwoo Pae, C., & Hyunwoo Pae, N. (2024). Advanced Predictive Autism Spectrum Disorder Screening Method. *International Journal of High School Research*, 6(2)
- [26] Nabil MA, Akram A, Fathalla KM. Applying machine learning on home videos for remote autism diagnosis: Further study and analysis. *Health Informatics Journal*. 2021;27(1). doi:[10.1177/1460458221991882](https://doi.org/10.1177/1460458221991882)
- [27] Gupta, S., & Pandey, D. (2024). Predicting autism spectrum disorder using the K-nearest neighbours algorithm in machine learning. *International Research Journal of Engineering and Technology (IRJET)*, 11(10), 403–407. <https://www.irjet.net/archives/V11/i10/IRJET-V111057.pdf>
- [28] Bousidrah, N. S., Khamees, Z. M., & Ali, S. M. (2024). Detection of Autism Spectrum Disorder by A Case Study Model Using Machine Learning Techniques.
- [29] Kadhum, S. W., & Tawfeeq, M. A. (2025). Early Detection of Autism Spectrum Disorder in Children Using Different Machine Learning Algorithms. *medRxiv*, 2025-04.
- [30] Gökalp, Ö. M. (2022). Makine öğrenmesi. Gazi Üniversitesi, Gazi BilişimEnstitüsü, Adli Bilişim Bölümü, 1-14.

7. Ekler